

96GBのPCで DeepSeek V4 Flashを動かしたい！

大きなモデルを、手元の1台で。「動いた」けれど「結局遅い」？ エージェント実用へのリアルな現在地。

モデル：DeepSeek V4 Flash
商用モデルとも比較される巨大モデル。

PC：Strix Halo・96 GiB
Ryzen AI MAX+ 395 / Radeon 8060S。

最適化の軌跡 | 試行ごとの生成速度

01 / まず動かす

約12 tok/s

96GBに収めて、手元で動かす

02 / 実装を変える

約17 tok/s

このPC向けの実装に切り替え

03 / 高速化処理を試す

約20 tok/s

「先読み」による高速化を追加

検証の結論 入った！ 速くなった（約21 tok/s）！ でもエージェント常用には「結局遅い」