

そもそも、96GBに入るのか？

「96GBあれば余裕」と思いきや、実はギリギリでした。
CPUとGPUで共有するため、96GB丸ごとをモデルに使えるわけではない。

モデルだけで約88%

OS認識RAM 92GB を基準



重みのファイルサイズ

残り：OS・実行環境 + KVキャッシュ

モデルは入った。
でも、残りはたった数GB。

モデルだけで約81GB。OS分を引くと残りは約11GB未満しかなく、この狭い隙間で「長い会話」と「高速化」を両立できるかが最初の壁となった。

それでも載せたい理由 - Claude Opus 4.8とのベンチマークの比較		
Terminal Bench 2.1	DeepSWE	NL2Repo
82.7 / 85.0	54.4 / 58.0	54.2 / 69.7