

圧縮したモデルを、96GBで動かす

本来なら到底動かない超巨大モデルを、実用性を損なわない限界まで圧縮し、このパソコンで動かした。

最初の達成 約81GBまで圧縮して読み込みに成功。実際に文章を生成できた。

モデル / WEIGHTS

まずは圧縮してねじ込む

賢さを維持できるギリギリまでデータを圧縮し、**96GBの枠内に収めた**。

実行 / INFERENCE

手元でちゃんと動いた！

専用ソフトで動かして**短い対話を確認**。Web系SWE-bench 30問では、Q2版もクラウドのフル精度版も**20/30 (66.7%)**を解決し、総合スコアの品質劣化は見られなかった。

ここでの到達点 起動には成功したものの、メモリの余白はわずか。次は「使われない部分を削る」手法を試す。