

モデルを削れば、もっと余裕ができる？

全体の圧縮に続いて、普段あまり使われない部分を切り落とす手法（REAP）を試した。

試したこと

出番の少ない部分を削る

利用頻度の低い回路を削ってモデルをスリム化し、浮いたメモリを会話や高速化に回そうと考えた。



結果

まさかの日本語崩壊…

容量は削減できたものの、日本語で入力すると怪文書が返る状態に。普段使いのモデルとしては採用を見送った。

アシスタント

Віс. На рус. Привет. Можно предложить help.

ユーザー

こんにちは

この試行の結論 「読み込める」 だけでは不十分。自然な日本語で会話できることが必須条件。