

動かす方法を変えて、生成を速くする

96GBに入っても、文字が出るのをじっと待つようでは使いづらい。
次の課題は、生成スピードだった。

mainline llama.cpp / Vulkan

約11 tok/s



strix-halo-llamacpp / Vulkan

約17 tok/s

動くけれど、待たされる

DwarfStarの初期構成では文字が出るテンポが遅く、実用には物足りない。メモリに収めるだけでは快適に使えないことがわかった。

このパソコン専用の実装に乗り換え

既存の高速化手法（ds4fa）ではメモリ不足で断念。そこで他の、このPC専用に最適化された**strix-halo-llamacpp**へ切り替え、速度を上げることができた。