


高速化手法を取り入れてみる

さらに速く生成したい。ただ「先読み役」を追加すると、今度はメモリが足りない。

「先読み」でまとめて文字を出す

毎回大きなメインモデルを動かす代わりに、軽い「先読み役」に次の単語候補を複数作らせ、メインがまとめて検証する仕組みを導入した。



先読み役を載せると、メモリ不足に

すでにギリギリのメモリにもう1つモデルを載せるため、長い会話を試すとメモリ不足で止まってしまう問題が生じた。

速くするために追加した先読み役自体も、メモリを圧迫しないよう軽量化する必要に迫られた。

本体を削ると日本語が崩れる。それなら「先読み役」だけを削る。

4枚目の失敗を踏まえ、メインではなく先読み役だけを軽量化。約2GBのメモリを節約しつつ、生成スピードもほぼ維持できた。