

で、実際どれくらい速い？

先読みで生成スピードが約1.3倍に。
先読み役を軽量化しても、速さはほぼ同じ。

出力する速さ Decode

条件を揃えて測定した、1秒あたりの生成トークン数（各構成8回の平均）



入力を読む速さ Prefill

1,233トークンの指示を入力したときの処理速度を比較



先読みはどれくらい当たる？ 採用率

先読み役が出した候補のうち、メインモデルに採用された割合

