

結局、実用レベルになった？

96GBの制約でも動かすことはできた。速くもなった。 ただ、エージェント用途ではまだ遅い...

約21 tok/sまで引き上げたものの、常用には30~50 tok/s欲しい。さらに長文ファイル読込（Prefill）の遅さやスワップの懸念も残った。

使用感 | 生成速度（Decode）

回答に数分待ち。最低30 tok/sは必要

普段のエージェント利用では50 tok/s超を使っており、最低でも30 tok/sが実用ライン。約21 tok/sでは回答に数分待たされ厳しい。

使用感 | 読込（Prefill）とメモリ

ファイル読込の遅さと、スワップの影

コードやファイルを読み込むPrefillに時間がかかる。また、検証中にわずかなスワップ使用履歴も確認された。96GBあっても極限状態のため、他アプリを極力落とした専用環境での運用が前提になる。

今後の展望

エージェント実用の目安となる30 tok/s 台を目指す。ファイル読込（Prefill）の高速化やさらなる軽量化を進め、これ以上メモリ使用量を増やさない範囲で最適運用を追求したい。



noteで続きの研究を掲載予定！

展示の深掘り・やり残した最適化の検証

展示で触れきれなかった詳細情報やログに加え、カーネル最適化など今回やり足りなかった技術的挑戦の続きをnoteで順次公開予定！

<https://note.com/observer2003>